

Detecção de Utensílios de Cozinha Usando IA

FIAP - Inteligência Artificial - 1TIAOR 2024/2
Jônatas Gomes Alves – RM559693

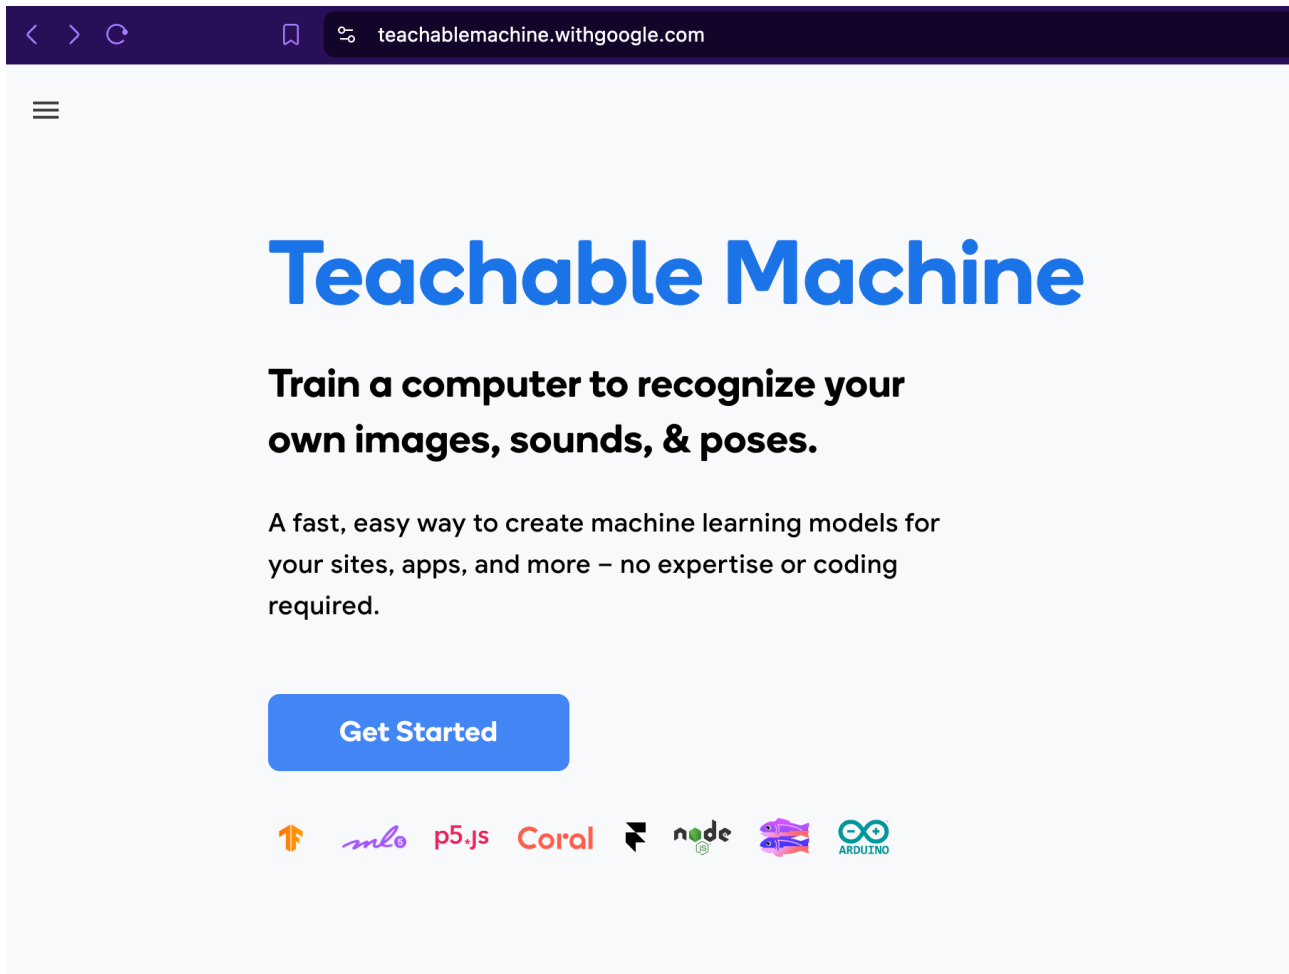
Objetivos e metodologia utilizada

Desenvolver um modelo de IA para detectar e classificar utensílios de cozinha a partir de fotos, explorando conceitos de aprendizado de máquina e visão computacional, utilizando o Teachable Machine, e avaliar a eficiência do modelo.

A metodologia consistiu na coleta de imagens de utensílios de cozinha, organizadas por categorias. Utilizando o Teachable Machine, foi treinado um modelo de IA para classificação de imagens, com diferentes classes. Após o treinamento, o modelo foi avaliado utilizando métricas como acurácia e precisão, e ajustes foram feitos para melhorar os resultados.

Principais etapas do projeto

Acessar o site <https://teachablemachine.withgoogle.com>, clicar em “Get Started”, escolher “Image Project” e “Standard image model”.




Na página do projeto, criar Classes para cada categoria desejada (talheres, panelas, preparo, limpeza) e adicionar imagens a cada uma delas usando o botão “Upload”.

≡ Teachable Machine

Talheres





10 Image Samples



Panelas



10 Image Samples



Em seguida, definir os parâmetros do treinamento e clicar em “Train Model”.


Teachable Machine

Talheres

10 Image Samples

Webcam

Upload

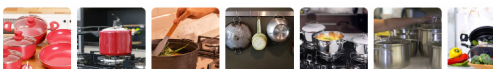


Panelas

10 Image Samples

Webcam

Upload




Preparo

10 Image Samples

Webcam

Upload




Limpeza

10 Image Samples

Webcam

Upload



Training

Train Model

Advanced

Epochs: 50

Batch Size: 16

Learning Rate: 0.001

Reset Defaults

Under the hood

Após o treinamento, selecionar “File” como o input a ser usado. Fazer o upload dos arquivos a serem testados e observar o output.

The interface is divided into two main sections: Training and Preview.

Training Section:

- Model Trained:** A button indicating the model is ready.
- Advanced:** A section with adjustable parameters:
 - Epochs:** Set to 50.
 - Batch Size:** Set to 16.
 - Learning Rate:** Set to 0.001.
- Reset Defaults:** A button to reset the parameters.
- Under the hood:** A button to view the model's internal structure.

Preview Section:

- Input:** A toggle switch is set to ON. A dropdown menu is set to "File".
- Choose images from your files, or drag & drop here:** A button with a folder icon to upload local files.
- Import images from Google Drive:** A button with a Google Drive icon to import images from the cloud.
- Image:** A photograph of a kitchen scene featuring a large knife, a piece of meat, and some vegetables.
- Output:** A list of classification results with corresponding progress bars:
 - Talher...** (Orange bar): 99%
 - Panelas** (Pink bar): 0%
 - Prepa...** (Purple bar): 0%
 - Limpe...** (Blue bar): 0%

Na primeira rodada de testes usando-se os valores default no treinamento, foi observada uma taxa de acerto de 100%.

Resultados obtidos

Em nossos testes foram utilizadas 4 classes: talheres, panelas, utensílios para preparo de comida, utensílios para limpeza. Cada classe usou 10 imagens obtidas no Google Images. Em todos os testes foram usadas 4 imagens, 1 de cada classe.

Abaixo segue uma tabela com os resultados observados em 4 rodadas de testes nas quais o “Learning Rate” foi modificado por um fator de 10x.

Rodada	Learning Rate	Acurácia
1	0.001	100%
2	0.01	100%
3	1	50%
4	10	50%

The screenshot displays the Teachable Machine web interface. On the left, four class cards are visible: 'Talheres' (Knives), 'Panelas' (Pots/Pan), 'Preparo' (Food Preparation), and 'Limpeza' (Cleaning). Each card shows '10 Image Samples' and buttons for 'Webcam' and 'Upload'. In the center, the 'Training' panel is active, showing 'Model Trained' and 'Advanced' settings: 'Epochs: 50', 'Batch Size: 16', and 'Learning Rate: 10'. On the right, the 'Preview' panel shows an input image of a knife and the output classification results: 'Talheres...' at 100%, 'Panelas', 'Prepa...', and 'Limpe...'.

Desempenho do modelo e melhorias

O modelo apresentou um desempenho satisfatório em condições controladas, com uma alta taxa de acurácia nas primeiras rodadas de testes, principalmente em learning rates mais baixas. Contudo, o aumento da taxa de aprendizado reduziu a acurácia em casos extremos, evidenciando a necessidade de ajustes finos nos hiperparâmetros para evitar problemas de overfitting e underfitting. Melhorias podem ser alcançadas com a ampliação do conjunto de dados, inclusão de mais classes de utensílios e ajustes nos parâmetros avançados do modelo, como épocas e batch size, visando um treinamento mais robusto e generalizado.